

Optymalizacja hurtowni danych

Sambor Seredyński
Maciej Kowalczyk

1. Cel laboratorium:

Celem zadania jest pokazanie zagadnień dotyczących różnych fizycznych modeli kostek oraz projektowania agregacji.

2. Założenia wstępne:

Rozmiar hurtowni danych:

Baza Źródłowa - 85,11 MB

Kostka OLAP (tryb MOLAP) - 27,65 MB

Kostka OLAP (tryb ROLAP) - 7,90 MB

Liczba wierszy testowanej tabeli faktów: 1 000 000

Środowisko testowe:

Pomiary dokonano na Lenovo IdeaPad Slim 5 wyposażonym w procesor Ryzen 7 8845HS, 24 GB pamięci RAM o prędkości 4800 MT/s i system operacyjny Windows 11. Do wyznaczenia czasów przetwarzania kostki wykorzystano SQL Server Management Studio z rozszerzeniem SQL Server Profiler. Podczas pomiarów na laptopie aktywnymi aplikacjami były SSMS, Visual Studio 2019 i przeglądarka z otwartymi instrukcjami.

3. Założenia teoretyczne:

	MOLAP	ROLAP
Czas przetwarzania kostki	Długi	Krótki
Czas wykonywania zapytań	Krótki	Długi
Rozmiar	Duży	Mały

4. Przeprowadzone testy

Celem przeprowadzonych testów było zbadanie wpływu trybu przechowywania (MOLAP vs ROLAP) oraz zastosowania agregacji na wydajność kostki analitycznej. Pomiar czasu wykonywania zapytań (Query Execution Time) oraz czasu procesowania kostki przeprowadzono w środowisku SQL Server Analysis Services (SSAS).

Aby wyeliminować błędy losowe i chwilowe obciążenia serwera, przyjęto następującą procedurę pomiarową:

- Każde zapytanie testowe zostało wykonane 10 razy dla każdej konfiguracji.
- Przed każdym pomiarem czyszczono pamięć podręczną (Cache) serwera SSAS, aby wymusić pełny odczyt danych.
- Jako wynik końcowy przyjęto średnią arytmetyczną z uzyskanych 10 pomiarów (w przypadku wystąpienia błędu grubego taki pomiar odrzucono).

Do testów wykorzystano trzy zróżnicowane zapytania MDX, które miały na celu sprawdzenie zachowania systemu w różnych scenariuszach analitycznych:

Zapytanie 1

```
SELECT
    NON EMPTY {
        [Measures].[LiczbaUczestnictw],
        [Measures].[SredniaOcenaUczestnictwa]
    } ON COLUMNS,
    NON EMPTY {
        [Dim_Data].[Hierarchy].[Miesiac].MEMBERS *
        [Dim_Typ_Zajec].[Nazwa].[Nazwa].MEMBERS
    } ON ROWS
FROM [Dw Schema];
```

Opis zapytania: Zapytanie generujące zestawienie krzyżowe (Crossjoin) dla dwóch kluczowych wymiarów: Czasu (na poziomie Miesiąca) oraz Typu Zajęć. Zadaniem serwera było obliczenie sumy uczestnictw oraz średniej oceny dla każdej kombinacji miesiąca i rodzaju zajęć w całym badanym okresie.

Dobór agregacji:

- **Wymiar Data:** Atrybut **Miesiac** ustawiono na Full.
- **Wymiar Typ Zajęć:** Atrybut **Nazwa** ustawiono na Full.

Zapytanie 2

```
SELECT
  NON EMPTY {
    [Measures].[LiczbaUczestnictw]
  } ON COLUMNS,
  NON EMPTY {
    [Dim_Data].[Hierarchy].[Dzien].MEMBERS
  } ON ROWS
FROM [Dw Schema]
WHERE ( [Dim_Data].[Rok].&[2024] );
```

Opis zapytania: Zapytanie pobierające dane na najniższym poziomie szczegółowości czasowej – poziomie Dnia. Zapytanie wymuszało pobranie miary LiczbaUczestnictw dla każdego dnia w roku, co wiąże się z koniecznością przetworzenia dużej liczby wierszy wynikowych.

Dobór agregacji:

- **Wymiar Data:** Atrybut **Dzien** ustawiono na Full.

Zapytanie 3

```
SELECT
  NON EMPTY {
    [Measures].[SredniaOcenaUczestnictwa],
    [Measures].[LiczbaUczestnictw]
  } ON COLUMNS,
  NON EMPTY {
    TOPCOUNT(
      [Dim_Instruktor].[Imie I Nazwisko].[Imie I Nazwisko].MEMBERS,
      10,
      [Measures].[LiczbaUczestnictw]
    )
  } ON ROWS
FROM [Dw Schema]
WHERE ( [Dim_Data].[Weekend].&[weekend] );
```

Opis zapytania: Zapytanie rankingowe wykorzystujące funkcję TOPCOUNT. Jego celem było znalezienie 10 najpopularniejszych instruktorów, ale tylko w kontekście zajęć odbywających się w weekendy. Wymaga to od silnika najpierw przefiltrowania danych, następnie ich agregacji, posortowania i odcięcia wyników.

Dobór agregacji:

- **Wymiar Instruktor:** Atrybut **Imie I Nazwisko** ustawiono na Full.

- **Wymiar Data:** Atrybut **Weekend** ustawiono na **Full**.

Wyniki bez agregacji:

Przetwarzanie		Zapytanie 1		Zapytanie 2		Zapytanie 3	
MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
7787	1885	136	196	74	223	73	256
7895	1865	56	218	66	186	33	169
7688	1857	65	193	68	175	22	236
7636	1805	69	190	66	179	26	210
7579	1949	65	180	57	177	31	182
7849	1895	62	188	59	183	52	165
7676	1847	54	212	57	180	23	165
7672	1935	57	180	52	177	35	230
7512	1860	57	243	59	183	28	169
7484	1860	77	179	59	183	30	176

Wyniki z agregacją:

Przetwarzanie		Zapytanie 1		Zapytanie 2		Zapytanie 3	
MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
8664	2200	56	208	46	198	88	215
8169	1945	12	170	11	172	27	159
8381	1874	10	177	9	169	38	136
8108	1915	10	165	8	162	30	138

8201	2032	11	168	7	154	30	173
8077	1804	14	178	10	164	24	167
8141	1761	12	174	7	158	28	163
8188	1795	9	172	10	159	29	168
8011	1783	11	159	12	157	29	150
8197	1824	9	150	10	166	30	146

Podsumowanie wyników bez agregacji:

	Przetwarzanie		Zapytanie 1		Zapytanie 2		Zapytanie 3	
	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
Średnia	7677,8	1875,8	62,4	197,9	61,7	180,3	31,1	189,1
SD	128,5	40,2	7,0	19,6	6,2	3,4	8,4	26,9

Podsumowanie wyników z agregacją:

	Przetwarzanie		Zapytanie 1		Zapytanie 2		Zapytanie 3	
	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
Średnia	8163,7	1859,2	10,9	168,1	9,3	162,3	29,4	155,6
SD	97,1	84,6	1,5	8,50	1,6	5,6	3,5	12,8

Bezpośrednie zestawienie wyników:

	MOLAP		ROLAP	
Agregacje	Tak	Nie	Tak	Nie
Zapytanie 1	10,9	62,4	168,1	197,9
Zapytanie 2	9,3	61,7	162,3	180,3
Zapytanie 3	29,4	31,1	189,1	155,6
Przetwarzanie	8163,7	7677,8	1859,2	1875,8

kostki				
--------	--	--	--	--

5. Wnioski

Przetwarzanie kostki

Podsumowując wyniki przetwarzania, czas wymagany dla modelu MOLAP był około 4-krotnie dłuższy niż dla modelu ROLAP (odpowiednio ~8 s dla MOLAP vs ~1,8 s dla ROLAP). Wynik ten pokrywa się z założeniami teoretycznymi obu metod. W trybie MOLAP system musi fizycznie pobrać wszystkie dane z relacyjnej bazy danych, skompresować je i zapisać w strukturze kostki. W przeciwieństwie do tego, ROLAP pobiera i przetwarza jedynie metadane wskazujące lokalizację informacji, bez duplikowania samych danych, co prowadzi do znacznie krótszego czasu procesowania.

Wykonywanie zapytań

Mimo że MOLAP wymaga więcej czasu na wstępne przetworzenie danych, rekompensuje to, drastycznie przyspieszając czas wykonywania zapytań. W testach bez agregacji, zapytania w trybie MOLAP były średnio 3-krotnie szybsze od zapytań ROLAP (np. ~62 ms vs ~197 ms dla Zapytania 1). Wynika to z faktu, że MOLAP nie musi odpytywać zewnętrznej bazy danych w momencie żądania, ponieważ wszystkie niezbędne informacje są już przechowywane w zoptymalizowanej strukturze wielowymiarowej. ROLAP natomiast musi tłumaczyć każde zapytanie MDX na język SQL i oczekiwać na odpowiedź serwera relacyjnego.

Agregacje

Wpływ agregacji na wydajność okazał się zależny od trybu przechowywania oraz złożoności zapytania.

W przypadku MOLAP, dla zapytań wymagających przetworzenia dużej liczby rekordów (Zapytanie 1 i 2), odnotowano spektakularny spadek czasu wykonania (z ~62 ms do ~10 ms). Jest to spowodowane faktem, że podczas wykonywania zapytania program nie musiał grupować miar "w locie", ponieważ zostało to wykonane już na etapie przetwarzania kostki. Dlatego właśnie można zauważyć, że średni czas przetwarzania kostki z agregacjami nieznacznie wzrósł – jest to koszt przygotowania gotowych wyników.

Warto jednak zauważyć, że stopień redukcji czasu zależy od natury zapytania. Dla Zapytania 3 (ranking instruktorów), czas nie uległ poprawie. Wynika to z faktu, że przy bardzo małej liczbie grup (mały wymiar instruktorów) i prostym filtrowaniu, narzut systemowy maskuje zysk z agregacji.

Wnioski końcowe

Przeprowadzone testy dostarczyły cennych informacji na temat charakterystyki wydajnościowej modeli fizycznych kostki. Wyniki w dużej mierze potwierdziły założenia teoretyczne:

- MOLAP: Dłuższy czas przetwarzania, ale bezkonkurencyjna szybkość zapytań (szczególnie po zastosowaniu agregacji).
- ROLAP: Szybkie przetwarzanie, ale wolniejszy czas odpowiedzi na zapytania.
- Agregacje: Są kluczowym mechanizmem optymalizacji dla złożonych zapytań w MOLAP, zamieniając czas procesora podczas ładowania na szybkość odpowiedzi dla użytkownika.